Міністерство освіти і науки України
Національний технічний університет України «КПІ» імені Ігоря Сікорського Кафедра обчислювальної техніки ФІОТ

ЗВІТ
з лабораторної роботи №1
з навчальної дисципліни «Аналіз та обробка природної мови (NLP)»

Тема:

Отримання і попередня фільтрація природної мови

Виконав:
Студент 3 курсу кафедри ОТ ФІОТ, Навчальної групи ІО-31
Григорчук Д. С.
Перевірив:
Асистент кафедри ОТ ФІОТ
Баран Данило Романович

Київ 2026

І. Мета:
Дослідити процеси отримання та попередньої фільтрації повідомлень природною мовою з використанням спеціалізованих пакетів / бібліотек python.
ІІ. Завдання:

Завдання І, рівня складності – максимально 8 балів.

Розробити скрипт мовою python з процесами та функціоналом:

1. Обрати джерело даних – природньої мови, наприклад інформаційна стрічка новин, технічна документація, публіцистичні тексти, аналітичні статті, книги. **Увага!!!** Інформаційний контент має бути поданий українською або англійською мовами та мати коректний контент.
2. Провести парсинг / скрапінг даних обраного інформаційних джерел з отриманням інформаційного контенту, поданого природньою мовою.
3. Провести попередню фільтрацію результатів парсингу / скрапінгу обраного інформаційного джерела із фокусом на обраний контент.

Фільтрація має на меті прибрати все зайве, що захаращує чи змінює інформаційний контент.

4. Результати фільтрації систематизувати залежно від структури інформаційного контенту та зберегти у файлі. Тип файлу має відповідати структурі інформаційного контенту.
5. Результатом є файл з обраним інформаційним контентом після фільтрації.

ІІІ. Результати виконання лабораторної роботи

3.1 Синтезована математична модель;

Синтезована математична модель в даній лабораторній роботі включає в себе основні компоненти отримання, обробки та попередньої фільтрації текстових даних природної мови з веб-ресурсу BBC News.

1. Модель отримання HTML-документа

Процес роботи програми починається з надсилання HTTP-запиту до веб-ресурсу BBC News. У відповідь сервер повертає HTML-документ, що містить текстові дані та службову HTML-розмітку.

Для реалізації HTTP-запиту використовується бібліотека requests.

2. Модель аналізу HTML-структури

Отриманий HTML-документ аналізується як DOM-структура веб-сторінки. Для пошуку новин використовуються HTML-теги посилань <a> з атрибутом href.

Аналіз структури документа виконується за допомогою бібліотеки BeautifulSoup.

3. Фільтрація новин

Після отримання списку посилань виконується фільтрація новин за наступними умовами:

- наявність текстового заголовка;
- мінімальна довжина заголовка;
- відповідність URL формату новин BBC.

Фільтрація дозволяє прибрати службові або неінформативні посилання.

4. Витяг тексту статті

Для кожної знайденої новини програма переходить за URL-посиланням та отримує повний текст статті.

Текст формується шляхом об’єднання HTML-параграфів <p>.

5. Очищення тексту

Отриманий текст проходить попередню фільтрацію та очищення від:

- зайвих пробілів;
- переносів рядків;
- службових символів;
- коротких неінформативних фрагментів.

Для очищення тексту використовуються регулярні вирази (re).

6. Формування структури даних

Кожна новина представляється у вигляді структурованого об’єкта з полями:

- title;
- url;
- text.

Сукупність таких об’єктів формує структурований набір даних.

7. Збереження результатів

Отримані результати систематизуються та зберігаються у файл формату CSV. Файл містить:

- заголовок новини;
- URL-посилання;
- текст статті.

3.2 Результати архітектурного проектування та їх опис;

Блок-схема процесу функціонування системи

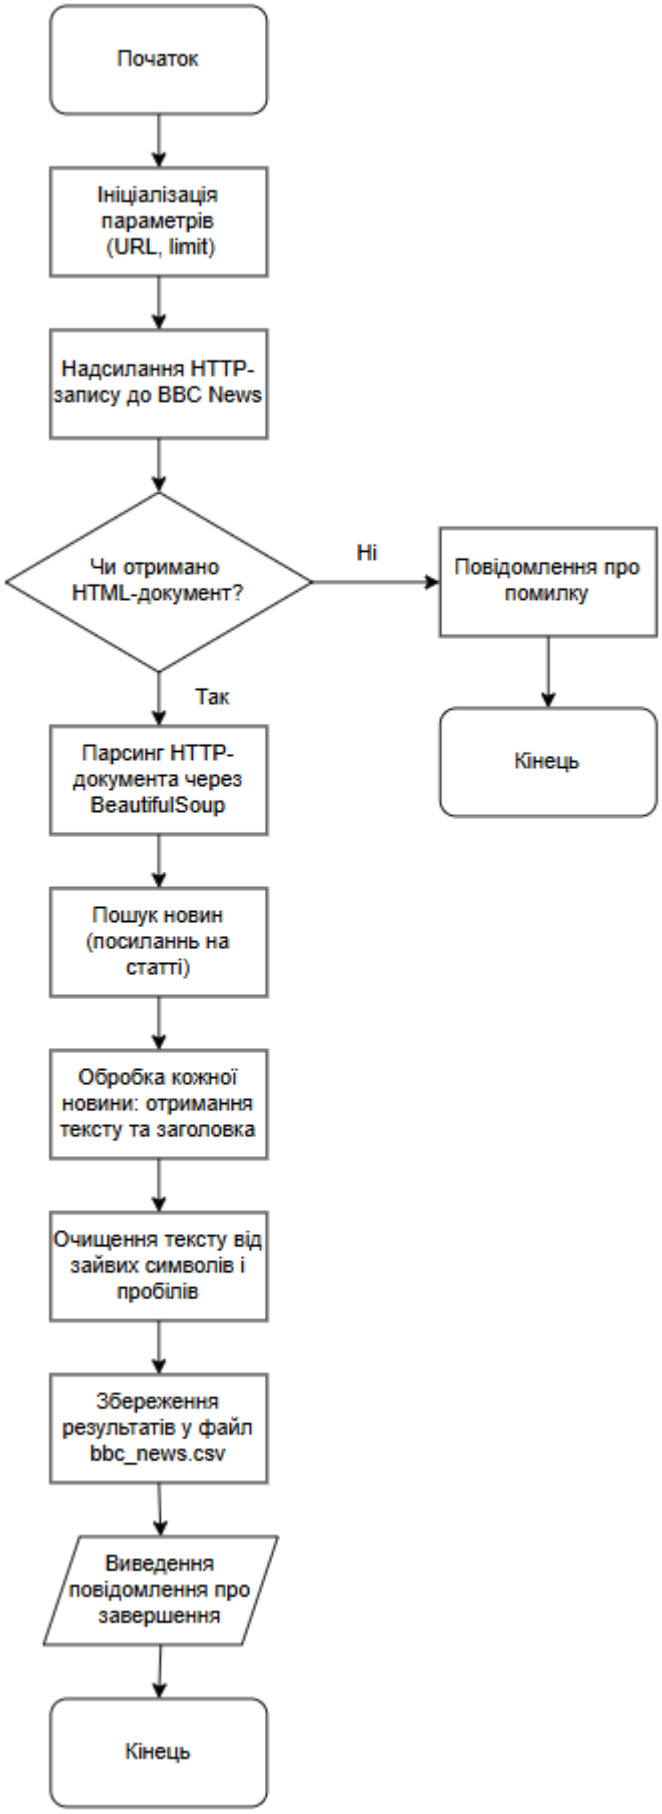

Опис блок-схеми алгоритму
Блок-схема відображає послідовність виконання програми для отримання та попередньої обробки текстового контенту з веб-ресурсу BBC News.

Алгоритм починається з ініціалізації основних параметрів програми: адреси веб-сайту, базового URL та ліміту кількості новин для обробки. Після цього програма надсилає HTTP-запит до сторінки BBC News.
Далі виконується перевірка отримання HTML-документа. Якщо сторінку не вдалося завантажити, програма виводить повідомлення про помилку та завершує роботу. Якщо HTML-документ отримано успішно, він передається на подальшу обробку.

На наступному етапі HTML-документ аналізується за допомогою бібліотеки BeautifulSoup. Програма здійснює пошук посилань на новинні статті та відбирає тільки ті посилання, які відповідають формату новин BBC.
Після цього виконується обробка кожної знайденої новини: отримується заголовок, URL-посилання та текст статті. Текст новини витягується з HTML-параграфів, після чого проходить попередню фільтрацію.
Під час очищення тексту видаляються зайві пробіли, переноси рядків та неінформативні фрагменти. Очищені дані формуються у структурований набір, який містить заголовок новини, посилання та текст статті.

Після завершення обробки новин результати зберігаються у файл bbc_news.csv. Наприкінці програма виводить повідомлення про успішне завершення роботи та завершує виконання.

3.3. Опис структури проекту програми;

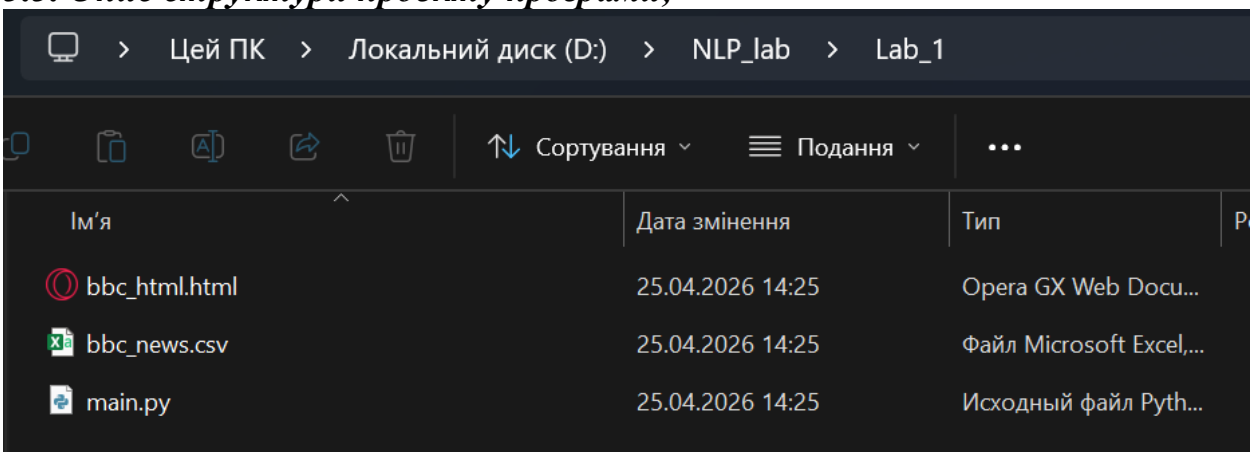

Для реалізації розробленого алгоритму мовою програмування Python з використанням можливостей інтегрованого середовища Visual Studio Code було сформовано програмний проєкт.

Проєкт побудований за принципом послідовної обробки даних та включає основні компоненти отримання, аналізу, очищення та збереження текстової інформації з веб-ресурсу BBC News.

Структура проєкту включає наступні файли:

- main.py — основний файл програми, який містить:
  - формування HTTP-запиту;
  - завантаження HTML-документа;
  - парсинг HTML-структури;
  - витяг заголовків, URL та тексту новин;
  - очищення текстових даних;
  - систематизацію результатів;
  - збереження результатів у CSV-файл.
- bbc_html.html — файл зі збереженим HTML-кодом веб-сторінки BBC News, який використовується для аналізу структури сторінки та перевірки результатів парсингу.
- bbc_news.csv — файл результатів роботи програми, який містить структуровані дані новин після попередньої фільтрації та обробки.

Отож, структура проєкту розділяє етапи отримання, аналізу та збереження текстових даних природної мови.

3.4. Результати роботи програми відповідно до завдання;

```
PS D:\NLP_lab\Lab_1> py main.py
Завантаження BBC News...
Обробка новини: Bowen: Strait of Hormuz standoff raises risk of sliding back into all-out war The US and Iran's determination to keep the pressure on each other has put the fragile Gulf ceas
efire in serious jeopardy. 7 hrs agoWorld
Обробка новини: French political row over calls for overhaul and €1bn cuts at public broadcasterA parliamentary committee of enquiry levelled charges of left-wing bias at state-owned France
Télévisions and Radio France.4 hrs agoEurope
Обробка новини: Police officer tells of operation to retrieve human remains from crocodileDNA tests are underway to confirm whether remains found inside the crocodile match that of a missing
 man.56 mins agoAfrica
Обробка новини: Russian attacks kill at least 20 ahead of rival ceasefires proposed by Kyiv and MoscowKyiv said it would begin a truce on 6 May and then "act symmetrically" after Moscow decl
ared a pause for its Victory Day parade.2 hrs agoEurope
Обробка новини: Hantavirus may have spread between passengers on cruise ship, WHO saysTwo cases of the virus, which rarely spreads between humans, have been confirmed on the ship, and three
people have died.2 hrs agoAfrica
Обробка новини: The most talked-about looks at this year's Met Gala The theme for 2026 Met Gala fundraiser is "Costume Art", exploring fashion as an embodied art form.14 hrs agoUS & Canada
Обробка новини: Dangerous baby-sleep advice given to parents by self-described experts, secret filming revealsThe advice puts babies at risk of serious harm, even death, medical professional
s have told the BBC.13 hrs agoFamily & Education
Обробка новини: Romanian PM ousted in no-confidence vote
Обробка новини: A 'fun' superstar stuns rivals and reshapes politics in an Indian state
Обробка новини: Daniel Radcliffe and Rose Byrne nominated for Tony Awards
Обробка новини: Two killed and many injured after car driven into crowd in German city of Leipzig
Обробка новини: Gap co-founder and retail pioneer dies aged 94
Обробка новини: Cruise passengers tell of life on board stranded ship after hantavirus outbreakWhile passengers onboard the MV Hondius say the situation is calm, they face days at sea as off
icials warn the disease may have spread.3 hrs agoAfrica
Обробка новини: What to know about Louise Arbour, Canada's next governor generalPrime Minister Mark Carney has appointed a new governor general - a largely symbolic but important role repres
enting King Charles III in Canada.2 hrs agoUS & Canada
Обробка новини: Matt Damon seen in new trailer for Christopher Nolan's The OdysseyChristopher Nolan's movie, based on the Greek epic, also stars Anne Hathaway and Robert Pattinson.8 hrs agoC
ulture
Обробка новини: How Broadway star Lea Salonga changed the rules and opened the door for Asian actorsBroadway icon and Disney princess Lea Salonga has paved the way for Asian actors - but it
hasn't been easy.20 hrs agoAsia
Обробка новини: What does Trump's 'Project Freedom' in Strait of Hormuz entail?What does the operation entail and could it lead to a resumption of hostilities? 5 hrs agoWorld
Обробка новини: Robots move in as waste firms struggle to find staffHumanoid robots are being added to the automation of waste sorting.19 hrs ago
Обробка новини: Deadly China plane crash was caused by fuel cut-off, says reportThe Boeing 737 plane crashed into a Chinese hillside in 2022, killing all 132 people on board.14 hrs agoAsia
Обробка новини: Dolly Parton cancels Las Vegas residency over health issuesThe 80-year-old country music star said it will take some time for her to be "stage-performance ready" again.21 hrs
 agoUS & Canada
Знайдено і оброблено новин: 20
Дані збережено у файл bbc_news.csv
PS D:\NLP_lab\Lab_1>
```

Excel:

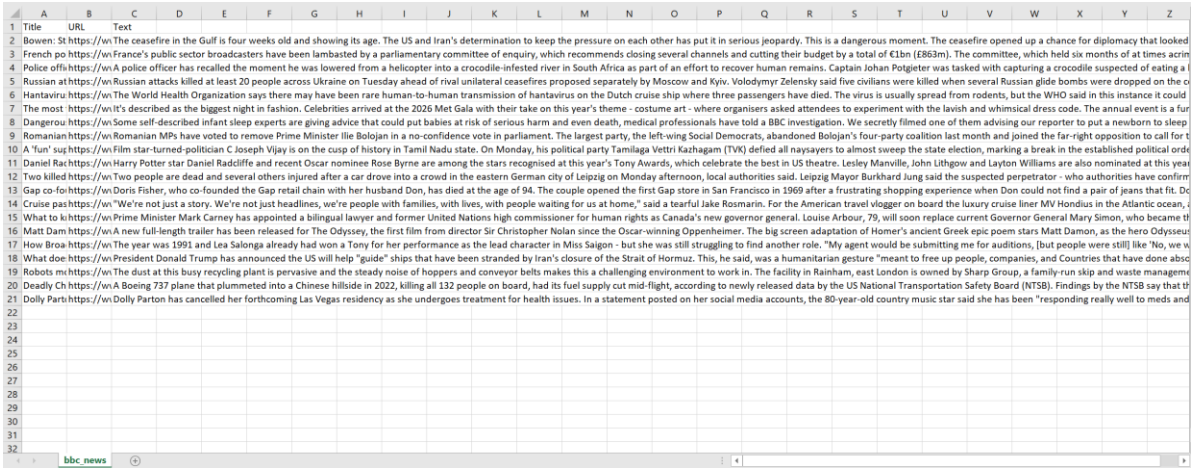

Title	URL	Text
Bowen: St	https://ww	The ceasefire in the Gulf is four weeks old and showing its age. The US and Iran's determination to keep the pressure on each other has put it in serious jeopardy. This is a dangerous moment. The ceasefire opened up a chance for diplomacy that looked
French po	https://ww	France's public sector broadcasters have been lambasted by a parliamentary committee of enquiry, which recommends closing several channels and cutting their budget by a total of €1bn (£863m). The committee, which held six months of at times acrim
Police offi	https://ww	A police officer has recalled the moment he was lowered from a helicopter into a crocodile-infested river in South Africa as part of an effort to recover human remains. Captain Johan Potgieter was tasked with capturing a crocodile suspected of eating a l
Russian at	https://ww	Russian attacks killed at least 20 people across Ukraine on Tuesday ahead of rival unilateral ceasefires proposed separately by Moscow and Kyiv. Volodymyr Zelensky said five civilians were killed when several Russian glide bombs were dropped on the c
Hantaviru	https://ww	The World Health Organization says there may have been rare human-to-human transmission of hantavirus on the Dutch cruise ship where three passengers have died. The virus is usually spread from rodents, but the WHO said in this instance it could
The most	https://ww	It's described as the biggest night in fashion. Celebrities arrived at the 2026 Met Gala with their take on this year's theme - costume art - where organisers asked attendees to experiment with the lavish and whimsical dress code. The annual event is a fur
Dangerou	https://ww	Some self-described infant sleep experts are giving advice that could put babies at risk of serious harm and even death, medical professionals have told a BBC investigation. We secretly filmed one of them advising our reporter to put a newborn to sleep
Romanian	https://ww	Romanian MPs have voted to remove Prime Minister Ilie Bolojan in a no-confidence vote in parliament. The largest party, the left-wing Social Democrats, abandoned Bolojan's four-party coalition last month and joined the far-right opposition to call for t
A 'fun' sup	https://ww	Film star-turned-politician C Joseph Vijay is on the cusp of history in Tamil Nadu state. On Monday, his political party Tamilaga Vettri Kazhagam (TVK) defied all naysayers to almost sweep the state election, marking a break in the established political orde
Daniel Rac	https://ww	Harry Potter star Daniel Radcliffe and recent Oscar nominee Rose Byrne are among the stars recognised at this year's Tony Awards, which celebrate the best in US theatre. Lesley Manville, John Lithgow and Layton Williams are also nominated at this year
Two killed	https://ww	Two people are dead and several others injured after a car drove into a crowd in the eastern German city of Leipzig on Monday afternoon, local authorities said. Leipzig Mayor Burkhard Jung said the suspected perpetrator - who authorities have confirm
Gap co-fo	https://ww	Doris Fisher, who co-founded the Gap retail chain with her husband Don, has died at the age of 94. The couple opened the first Gap store in San Francisco in 1969 after a frustrating shopping experience when Don could not find a pair of jeans that fit. Do
Cruise pas	https://ww	"We're not just a story. We're not just headlines, we're people with families, with lives, with people waiting for us at home," said a tearful Jake Rosmarin. For the American travel vlogger on board the luxury cruise liner MV Hondius in the Atlantic ocean, a
What to k	https://ww	Prime Minister Mark Carney has appointed a bilingual lawyer and former United Nations high commissioner for human rights as Canada's new governor general. Louise Arbour, 79, will soon replace current Governor General Mary Simon, who became th
Matt Dam	https://ww	A new full-length trailer has been released for The Odyssey, the first film from director Sir Christopher Nolan since the Oscar-winning Oppenheimer. The big screen adaptation of Homer's ancient Greek epic poem stars Matt Damon, as the hero Odysseus
How Broa	https://ww	The year was 1991 and Lea Salonga already had won a Tony for her performance as the lead character in Miss Saigon - but she was still struggling to find another role. "My agent would be submitting me for auditions, [but people were still] like 'No, we w
What doe	https://ww	President Donald Trump has announced the US will help "guide" ships that have been stranded by Iran's closure of the Strait of Hormuz. This, he said, was a humanitarian gesture "meant to free up people, companies, and Countries that have done absc
Robots m	https://ww	The dust at this busy recycling plant is pervasive and the steady noise of hoppers and conveyor belts makes this a challenging environment to work in. The facility in Rainham, east London is owned by Sharp Group, a family-run skip and waste manageme
Deadly Ch	https://ww	A Boeing 737 plane that plummeted into a Chinese hillside in 2022, killing all 132 people on board, had its fuel supply cut mid-flight, according to newly released data by the US National Transportation Safety Board (NTSB). Findings by the NTSB say that th
Dolly Part	https://ww	Dolly Parton has cancelled her forthcoming Las Vegas residency as she undergoes treatment for health issues. In a statement posted on her social media accounts, the 80-year-old country music star said she has been "responding really well to meds and

bbc_news

3.5. Програмний код, що забезпечує отримання результату:

```python
import requests
from bs4 import BeautifulSoup
import csv
import re
import time


BASE_URL = "https://www.bbc.com"
START_URL = "https://www.bbc.com/news"


def clean_text(text):
    """Очищення тексту від зайвих пробілів і переносів."""
    if not text:
        return ""

    text = re.sub(r"\s+", " ", text)
    return text.strip()


def fetch_html(url):
    """Завантаження HTML-сторінки."""
    headers = {
        "User-Agent": "Mozilla/5.0"
    }

    try:
        response = requests.get(url, headers=headers, timeout=10)

        if response.status_code != 200:
            print(f"Помилка завантаження сторінки {url}: {response.status_code}")
            return None

        return response.text

    except requests.RequestException as error:
        print(f"Помилка HTTP-запиту: {error}")
        return None


def extract_article_text(article_url):
    """Витягування повного тексту новини."""
    html = fetch_html(article_url)

    if not html:
        return ""

    soup = BeautifulSoup(html, "html.parser")

    paragraphs = soup.find_all("p")
```

```python
    text_parts = []

    for paragraph in paragraphs:
        text = clean_text(paragraph.get_text())

        if len(text) > 30:
            text_parts.append(text)

    article_text = " ".join(text_parts)
    return clean_text(article_text)


def parse_bbc_news(html, limit=20):
    """Парсинг новин BBC: заголовок, посилання, текст."""
    soup = BeautifulSoup(html, "html.parser")

    links = soup.find_all("a", href=True)

    articles = []
    seen_urls = set()

    for link in links:
        title = clean_text(link.get_text())
        href = link.get("href")

        if not title or len(title) < 20:
            continue

        if not href.startswith("/news/articles/"):
            continue

        full_url = BASE_URL + href

        if full_url in seen_urls:
            continue

        seen_urls.add(full_url)

        print(f"Обробка новини: {title}")

        article_text = extract_article_text(full_url)

        if len(article_text) < 100:
            continue

        articles.append({
            "title": title,
            "url": full_url,
            "text": article_text
        })

        time.sleep(0.5)
```

```python
        if len(articles) >= limit:
            break

    return articles


def save_to_csv(data, filename):
    """Збереження результатів у CSV-файл."""
    with open(filename, "w", encoding="utf-8-sig", newline="") as file:
        writer = csv.writer(file, delimiter=";")

        writer.writerow(["Title", "URL", "Text"])

        for item in data:
            writer.writerow([
                item["title"],
                item["url"],
                item["text"]
            ])


def main():
    print("Завантаження BBC News...")

    html = fetch_html(START_URL)

    if not html:
        print("Не вдалося завантажити головну сторінку.")
        return

    with open("bbc_html.html", "w", encoding="utf-8") as file:
        file.write(html)

    news = parse_bbc_news(html, limit=20)

    print(f"Знайдено і оброблено новин: {len(news)}")

    if not news:
        print("Новини не знайдені.")
        return

    save_to_csv(news, "bbc_news.csv")

    print("Дані збережено у файл bbc_news.csv")


if __name__ == "__main__":
    main()
```

IV. Висновки.

У ході виконання лабораторної роботи було реалізовано програму для автоматизованого отримання та обробки текстових даних природної мови з веб-ресурсу BBC News.

Було використано бібліотеки requests та BeautifulSoup для здійснення web-скрапінгу. Отримані дані були очищені від зайвих символів за допомогою регулярних виразів та структуровані у вигляді таблиці.

Результати було збережено у CSV-файл для подальшого аналізу. Отриманий програмний продукт відповідає поставленим завданням лабораторної роботи.

Репозиторій з кодом:

https://github.com/doer00kg/NLP_Lab1